Systemy operacyjne

Wykład 9: Pamięć wirtualna

Po co nam pamięć wirtualna?

Ilość pamięci wirtualnej zużywanej przez wszystkie procesy?

```
ps -A -o vsz | awk '{s+=$1} END {print s/1024}'
```

Ilość faktycznie zużywanej pamięci fizycznej → `free`

- programy nie potrzebują całego swojego kodu w pamięci
  (rzadko korzystamy z całej funkcjonalności, w tym kodu obsługi błędów)
- … i wszystkich swoich danych
  (przydział tablic dla przypadków pesymistycznych)
- prawie cały kod możemy współdzielić
  (sekcja **`text`** programów jest tylko do odczytu → biblioteki współdzielone)
- … dane też da się współdzielić, tak długo jak ich nie zmieniamy
  (dzięki temu można implementować efektywnie **`fork`**)

Przestrzenie adresowe i stronicowanie

Procesy posługują się **adresami wirtualnymi** i żyją w **wirtualnej przestrzeni adresowej.** Podobnie jest z jądrem, przy czym ono zarządza również zasobami w **fizycznej przestrzeni adresowej**.

Procesor przy każdym dostępie do pamięci wykonuje **translację adresów** z wirtualnych na fizyczne z użyciem zintegrowanej **jednostki zarządzania pamięcią**.

W **stronicowaniu** cała przestrzeń adresowa jest podzielona na **strony**. Są bloki pamięci ustalonego rozmiaru 2^k, które zaczynają się zawsze pod adresem podzielnym przez 2^k. Strony leżą w **pamięci wirtualnej**, a **ramki stron** w **pamięci fizycznej**.

Stronicowanie i translacja adresów

Opis wirtualnej przestrzeni adresowej dla procesora znajduje się w **tabeli stron**. Na podstawie adresu wirtualnego stron procesor wyznacza **wirtualny numer strony**, a następnie **przechodzi tablicę stron** szukając **wpisu strony**, z której wyciąga **numer ramki strony**. Mniej znaczące bity adresu wirtualnego nie podlegają translacji.

Wpisy stron przechowują dodatkowe informacje.

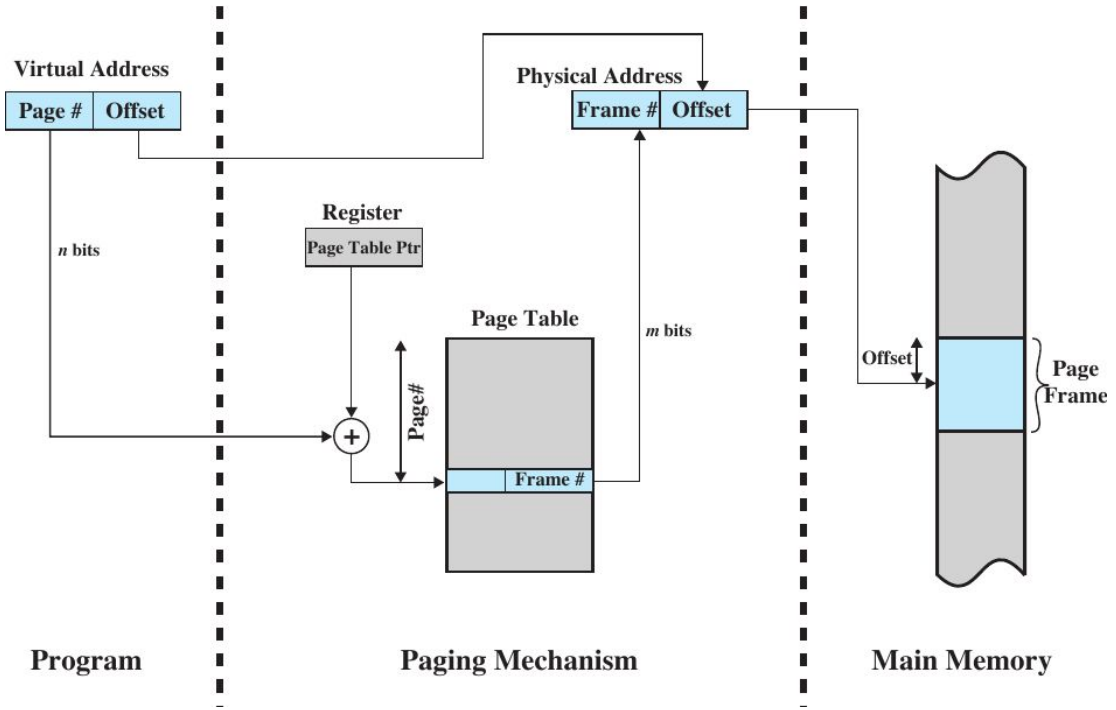

Tablica stron

Tablice stron mogą być różnie zorganizowane: **wielopoziomowa** (`Intel`, `ARM`), **odwrócona** (`PowerPC`), **wirtualna płaska** (`MIPS`). Chcemy by opis przestrzeni adresowej był jak najefektywniejszy!

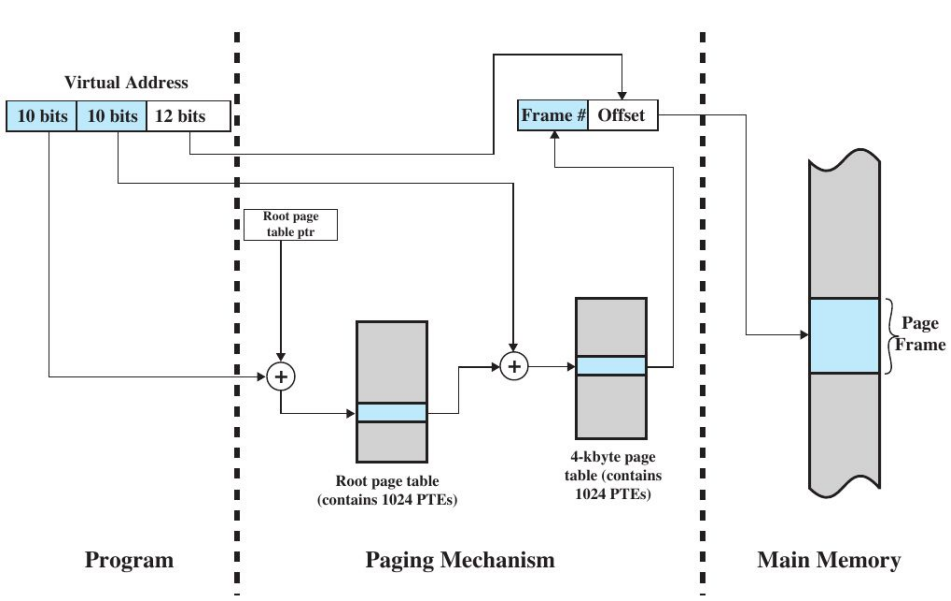

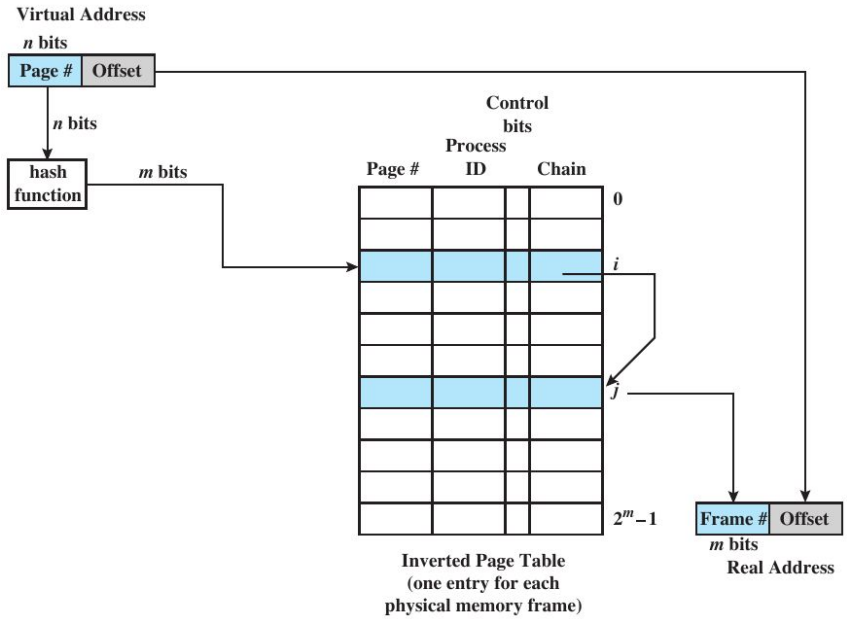

Wpisy tablicy stron

Wpisy tablicy stron oprócz fizycznego numeru strony zawierają:

- **bity uprawnień** → czy procesor może odczytywać, zapisywać, wykonywać zawartość strony?
- **bit obecności** → czy strona ma przypisaną ramkę?
- **bit trybu pracy procesora** → czy procesor będąc w trybie użytkownika albo nadzorcy może korzystać ze strony?
- **bity polityki buforowania** → czy i jak procesor może przechowywać zawartość strony w pamięci podręcznej?
  (disable cache, write-through, copy-back, etc.)
- **bity monitorowania dostępu** → czy ostatnio procesor czytał tą stronę (**referenced**) albo modyfikował (**modified**)?
  (będą nam potrzebne do implementacji polityk zastępowania stron)

Translation Lookaside Buffer

By translacja adresów przebiegała szybko procesory używają **TLB** – b. szybkiej pamięci podręcznej przechowującej wpisy stron.

Chybienie w TLB wymaga zajrzenia do tablicy stron.

Zasięg TLB to rozmiar pamięci, którą możemy zaadresować bez generowania chybienia.

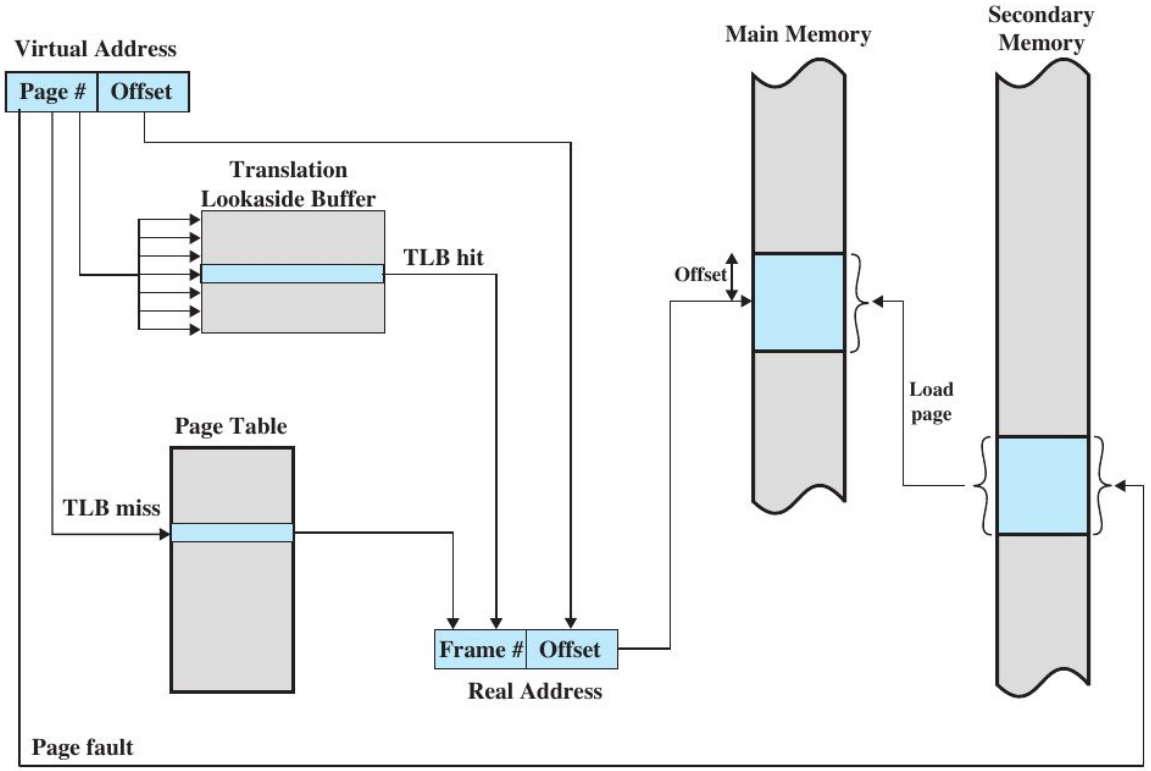

Zbiór roboczy i zbiór rezydentny

Zbiór roboczy to zbiór stron, których proces potrzebował w chwili t do działania w ciągu Δ ostatnich tyknięć wirtualnego zegara.

Zbiór rezydentny to zbiór wszystkich stron procesu rezydujących w pamięci operacyjnej w chwili t wirtualnego zegara procesu.

System operacyjny zarządza zbiorem rezydentnym i stara się przybliżać nim zbiór roboczy $\rightarrow$ chcemy by $W(t, \Delta) \subseteq R(t)$!

Znów będziemy polegać na **lokalności odwołań**, bo wiemy, że programy wykazują pewne wzorce w dostępach do pamięci!

Pomniejszy i poważny błąd strony

pomniejszy błąd strony (ang. *minor page fault*) → strona w pamięci operacyjnej, ale złe uprawnienia bądź nie podczepiona

poważny błąd strony (ang. *major page fault*) → strona w pamięci drugorzędnej, wymaga potencjalnie długiej operacji czytania, czas przełączyć się na inny proces

częstość błędów stron (ang. page fault frequency) → błędy stron można zliczać i analizować; można szybko stwierdzić czy rozmiar zbioru rezydentnego jest dopasowany do potrzeb procesu

```
ps -A -o pid,rss,vsz,min_flt,maj_flt,command
```


PAMIĘĆ WIRTUALNA MÓWISZ?
... JA TO CHYBA JUŻ WIDZIAŁEM
imgflip.com

Zarządzanie cache'm vs. pamięcią wirtualną

Jest wiele podobieństw i słusznie! Realizujemy te same cele, ale między innymi **poziomami hierarchii pamięci** tylko, że tym razem robimy to programowo, a nie sprzętowo!

blok → strona

metadane bloku → wpis tablicy stron

pamięć asocjacyjna → tablica stron

zastępowanie bloków → polityka zastępowania stron

cache miss → major page fault

pojemność pamięci podręcznej → rozmiar pamięci RAM

pobranie bloku z RAM → pobranie strony z dysku

polityka write-back → buforowanie stron

Polityka sprowadzania

polityka sprowadzania (ang. *fetch*) → uruchamiamy nowy program, najpierw musimy go wczytać… ale czy będziemy potrzebować całego jego kodu i wszystkich danych w pamięci operacyjnej od razu?

- leniwie → **stronicowanie na żądanie** (ang. *demand paging*)
  (błąd strony → ładujemy; a jeśli błędów jest dużo na krótkim odcinku czasu?)
- gorliwie → **stronicowanie wstępne** (ang. *prepaging*)
  (zauważamy, że sprowadzenie całej ścieżki z dysku lub jednego bloku nie różni się czasem → **czytanie z wyprzedzeniem** (ang. *read-ahead*))

Może dać programiście jakieś narzędzie do wyrażania intencji?

Polityka sprzątania

polityka sprzątania (ang. *clean*) → możemy wyznaczyć podzbiór ramek stron, z których programy nie korzystają od dłuższego czasu, ale są zmodyfikowane i wymagają uspójnienia z pamięcią drugorzędną. Kiedy je wyczyścić?

- leniwie → **czyszczenie na żądanie** (ang. *demand cleaning*)
  (jak musimy ponownie użyć danej strony to dopiero ją uspójniamy)
- gorliwie → **czyszczenie wstępne** (ang. *precleaning*)
  (zbieramy strony w grupy i wyrzucamy na dysk, może już nie będą potrzebne)

Lepsze podejście? **Buforowanie stron**, o którym będzie później.

Polityki przydziału

polityka przydziału (ang. *placement*) → sprowadzamy strony z pamięci drugorzędnej do RAM, czy to pod jakim adresem je umieścimy może mieć wpływ na wydajność programów? Tak!

- systemy z **niejednorodnym dostępem do pamięci** (ang. *Non-Uniform Memory Architecture*)
  (procesor ma “dalej” do pewnych fragmentów pamięci fizycznej)
- **kolorowanie stron** (ang. *page colouring*)
  (ułożenie danych w RAM może wpływać na liczbę chybień w pamięć cache)
- **duże strony** (ang. huge pages)
  (zwiększanie zasięgu TLB → mniej chybień w pamięciożernych programach)

Polityka zastępowania

polityka zastępowania (ang. *replacement*) → chcemy zmniejszyć zbiór roboczy programu, potrzebujemy wyznaczyć ramki stron, których proces nie będzie już potrzebować. Będziemy wybierać strony ofiary (ang. *victim*), a następnie wyrzucać je lub uspójniać z pamięcią drugorzędną. Oczywiście nie znamy przyszłości (idealny algorytm **`OPT`**) więc będzie trzeba sobie radzić inaczej.

- możemy badać czy proces odnosił się do stron w przeszłości
  (wsparcie sprzętowe → bity monitorowania dostępu referenced / modified)
- … i kojarzyć te informacje z wirtualnym czasomierzem procesu

… problem w tym, że będziemy popełniać błędy.

Podstawowe polityki zastępowania: **OPT**, **LRU**, **FIFO**

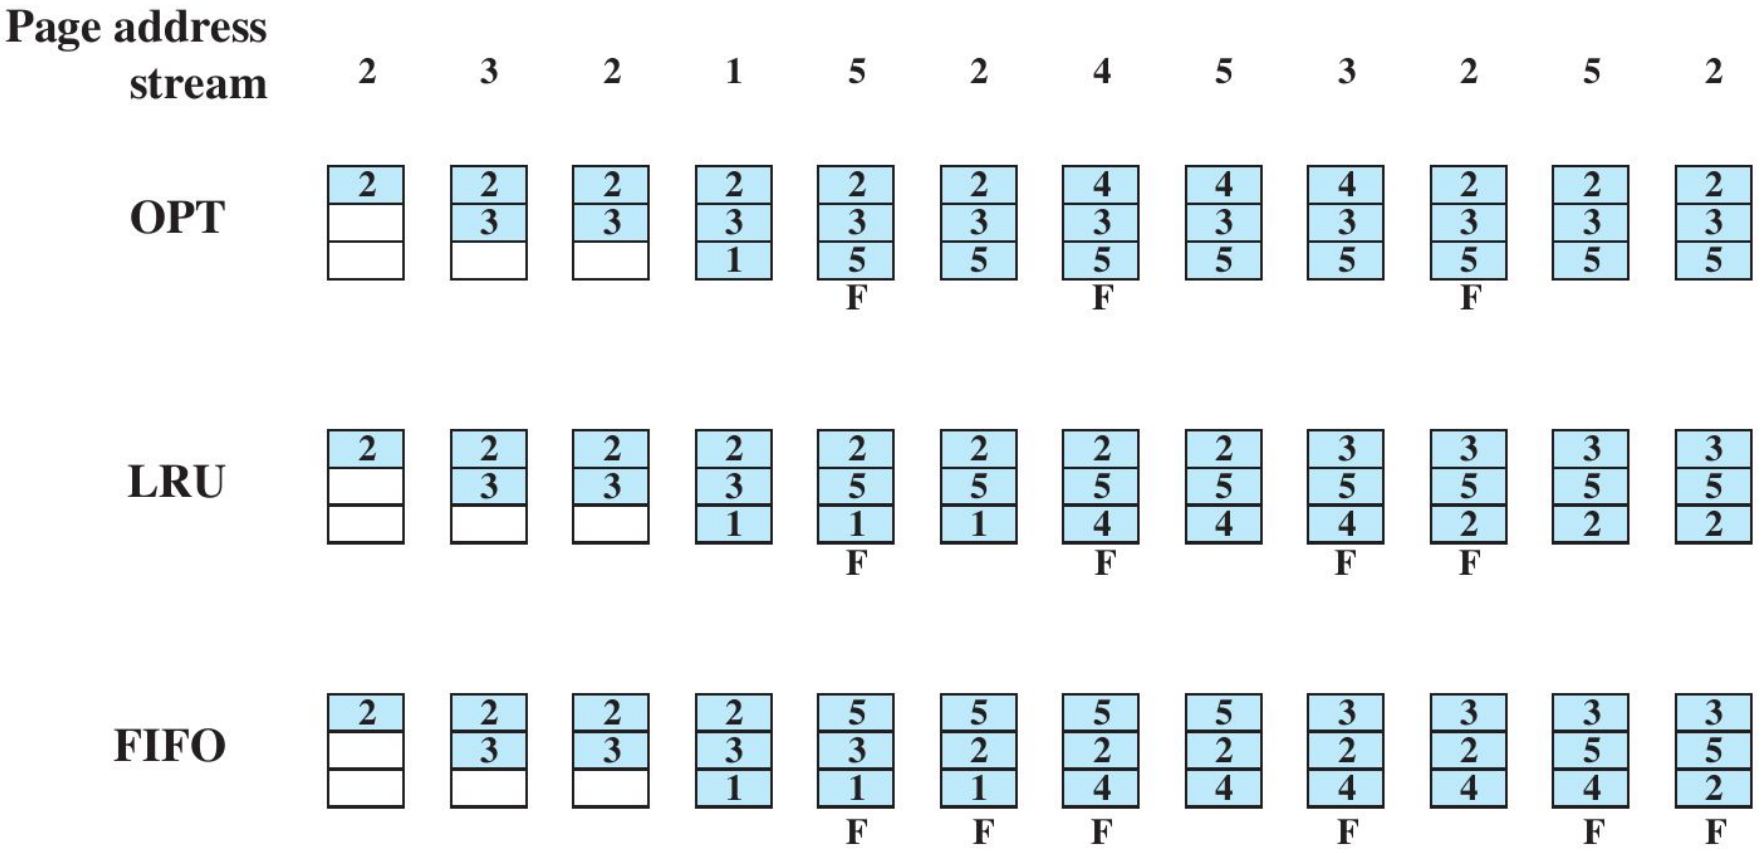

F → błąd strony zapoczątkowujący wybór ofiary do zastąpienia

Not Recently Used

Co każde tyknięcie wirtualnego zegara, np. 20ms, przeglądamy zbiór rezydentny procesu i na podstawie bitów monitorowania dostępu przypisujemy ramki do jednej z klas:

1. **`referenced`** `=` `0`, **`modified`** `=` `0` (ostatnio nieużywane)
2. **`referenced`** `=` `1`, **`modified`** `=` `0` (ostatnio używane)
3. **`referenced`** `=` `0`, **`modified`** `=` `1` (ostatnio nieużywane, brudne)
4. **`referenced`** `=` `1`, **`modified`** `=` `1` (ostatnio używane, brudne)

Szukamy ofiar do zastąpienia? Oczywiście nie chcemy stron z klasy 2 i 4. Najłatwiej wziąć strony z klasy 1. Strony z klasy 3 / 4 po **wyczyszczeniu** przechodzą do klasy 1 / 2.

Algorytm drugiej szansy i buforowanie stron

Algorytm FIFO nie patrzy na bit **`referenced`** wyrzucanej strony. Mógł być ustawiony na 1 → więc nie chcemy jej usuwać. Dajmy jej drugą szansę → wrzućmy ją do **bufora stron** zamiast czyścić.

demon stronicowania (ang. *paging daemon*) wątek jądra (**`kswapd`** w Linuksie) przegląda regularnie bufory stron i:

- za mało wolnych ramek → zacznij usuwać strony
- strona długo brudna (10s?) i dysk się nudzi → uspójnij
- strona czysta i nie używana bardzo długo → zapomnij
- strona czysta i bez właściciela → zapomnij

Q: Czemu w buforze stron mogą być ramki nienależące do żadnego procesu?
A: Przyspieszenie ładowania często wykorzystywanych programów.

Algorytm zegarowy (CLOCK)

Ramię zegara wskazuje na stronę kandydata na **ofiarę** do zastąpienia.

Występuje błąd strony:

1. `referenced=0` → usuwamy stronę
2. `referenced=1` → wyczyść bit, idź do następnej strony, powtórz od (1)

Wszystkie strony miały `R=1`? Algorytm degeneruje się do FIFO po okrążeniu!

Rozszerzenie: Można dodać drugie ramię, które będzie wyznaczać strony do wyczyszczenia.

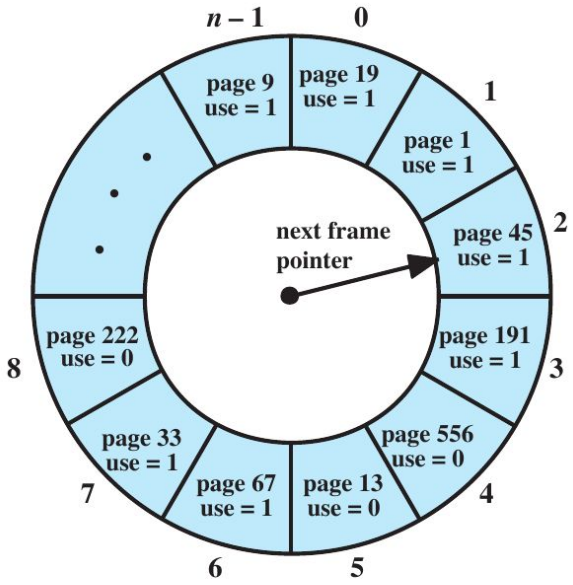

(a) State of buffer just prior to a page replacement

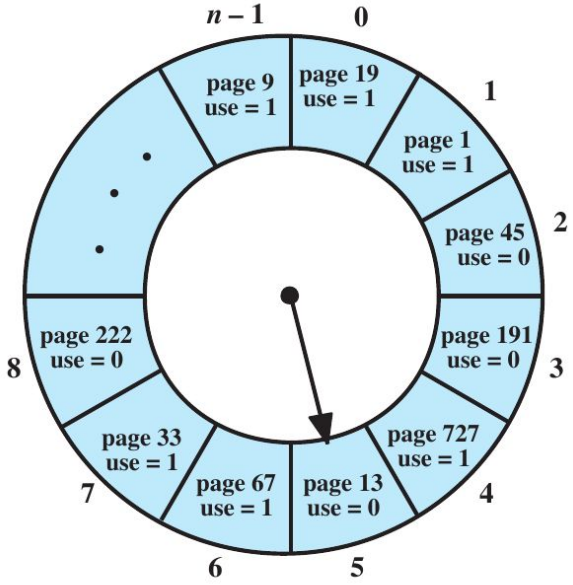

(b) State of buffer just after the next page replacement

Najrzadziej używana strona

Żeby zrobić dokładnie **LRU** (ang. Least Recently Used) trzeba wsparcia ze strony sprzętu. Do wpisów tablicy stron dodajemy licznik `C` odwołań (32-bit?, więcej?). Każdy dostęp → +1.

Obsługa błędu strony → bierzemy strony zbioru rezydentnego, sortujemy po `C` i wybieramy najmniejszy.

Wady: Sprzęt musi aktualizować liczniki. Większa tablica stron. $O(n \log n)$ na sortowanie przy każdym błędzie strony. Co jeśli liczniki się przepełniają?

Wsparcie sprzętowe nie istnieje. Koszt dokładnego algorytmu zbyt duży. Czy nie możemy jakoś przybliżać LRU?

Postarzanie stron (ang. *ageing*)

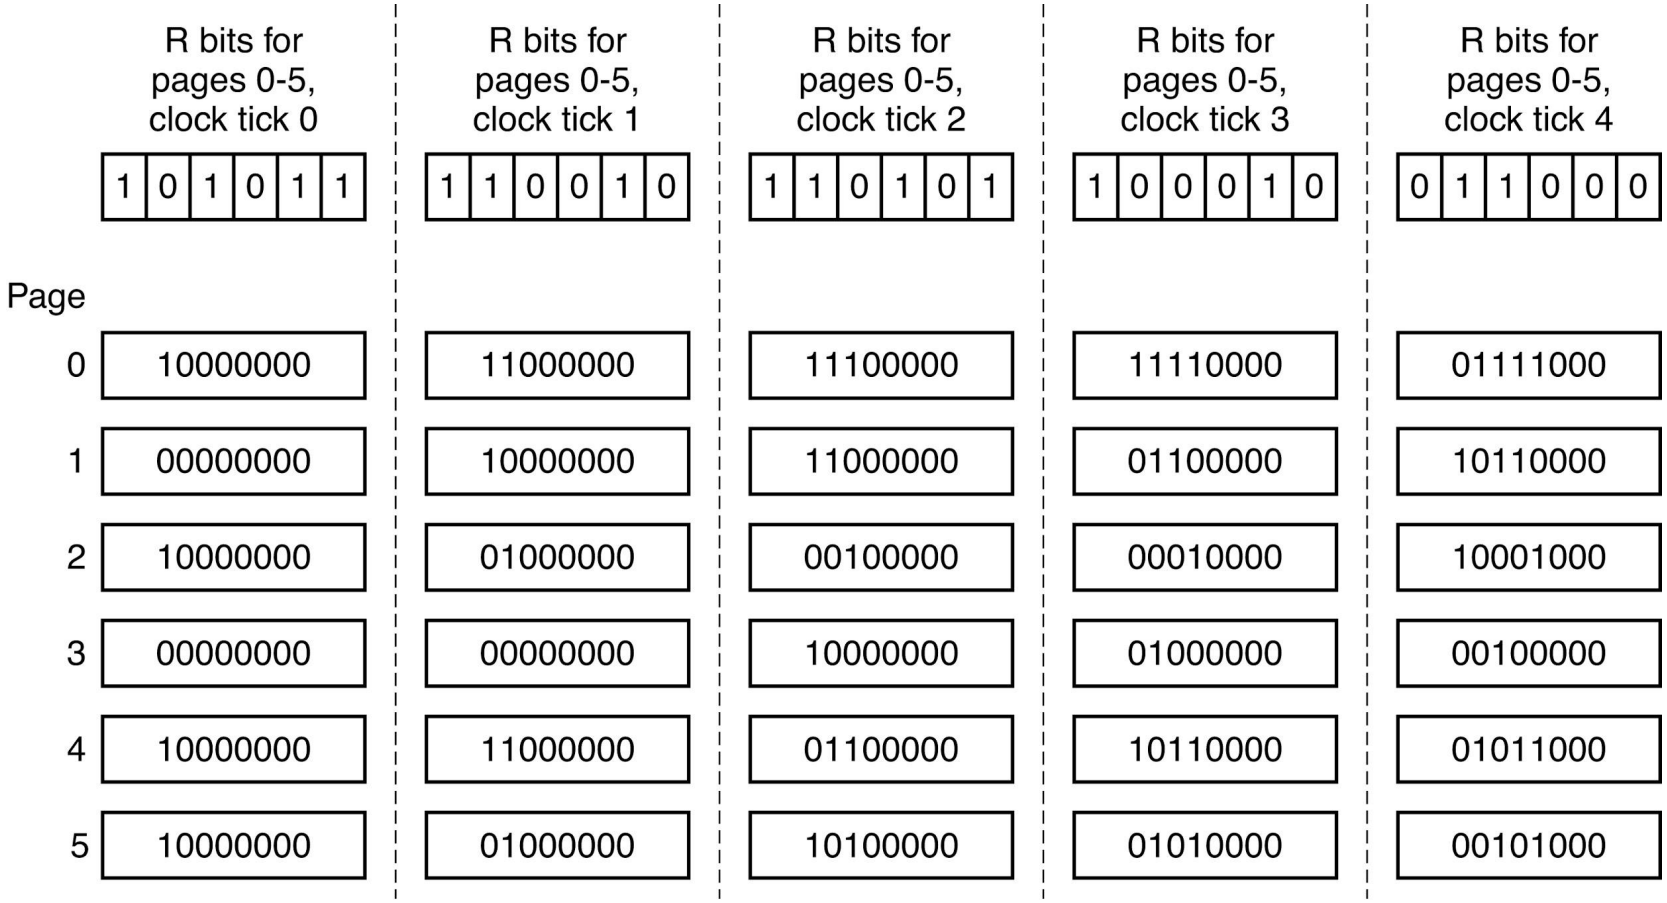

Stronom zbioru rezydentnego dajemy rejestr przesuwny. Bity dostępu wsuwamy od lewej co cykl wirtualnego zegara. Usuwamy stronę o najmniejszej wartości.

Modelowanie zbioru roboczego

Chcemy zastępować te strony zbioru rezydentnego, które nie są częścią zbioru roboczego. Sprzęt tego nie umożliwia!

Q: Jak wyznaczyć przybliżoną zawartość zbioru roboczego?
A: Niech zbiór roboczy to ramki używane w ciągu ostatnich τ milisekund.

Planista będzie mierzył na ile taktów uruchomiliśmy proces zanim znów znalazł się w jądrze → **bieżący czas wirtualny procesu**.

Ze stronami zbioru rezydentnego kojarzymy **czas ostatniego użycia** (ang. *timestamp*). Co tyknięcie zegara przeglądamy strony:

- `ref` = `0` i age > τ → usuwamy stronę
- `ref` = `1` → `ref` ← `0` i ustawiamy znacznik na obecny czas.

WSClock (1)

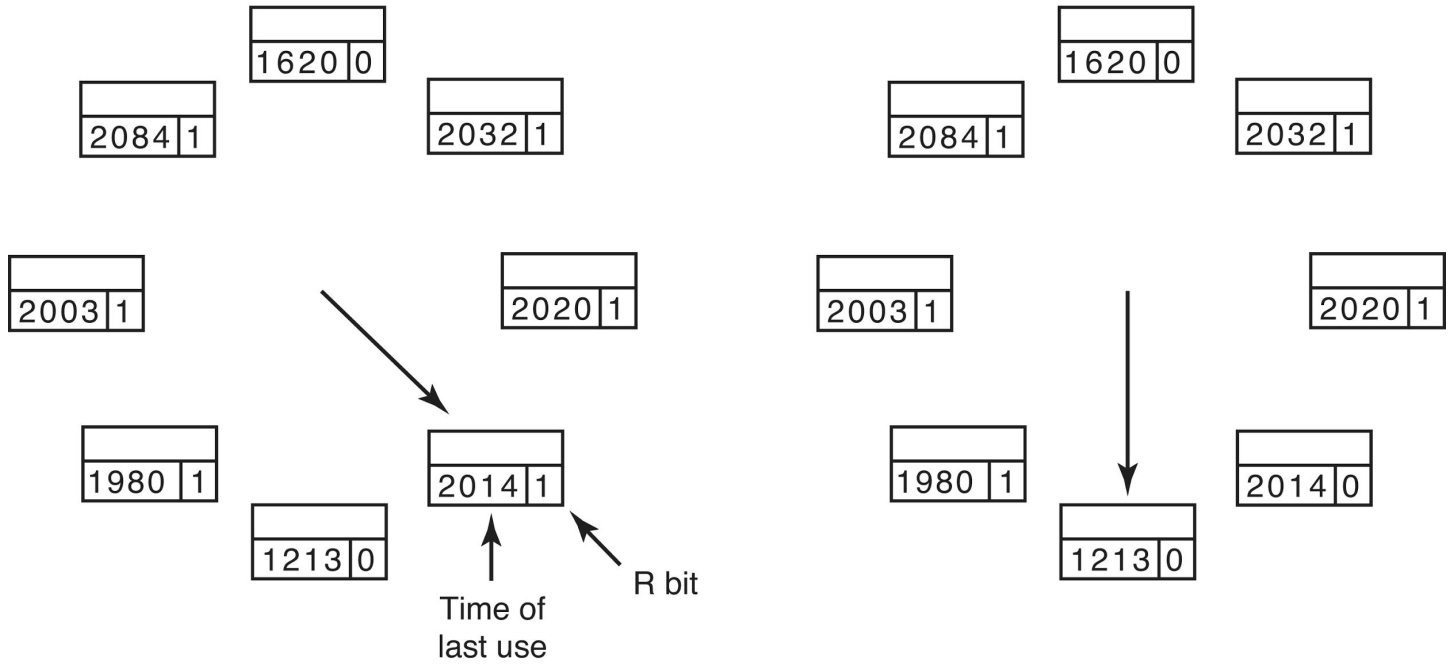

Szybki i stosowany w praktyce algorytm modelujący zbiór roboczy.

Bieżący czas wirtualny `2204`. Bit `modified` ukryto. Niech $\tau = 250$.

WSClock (2)

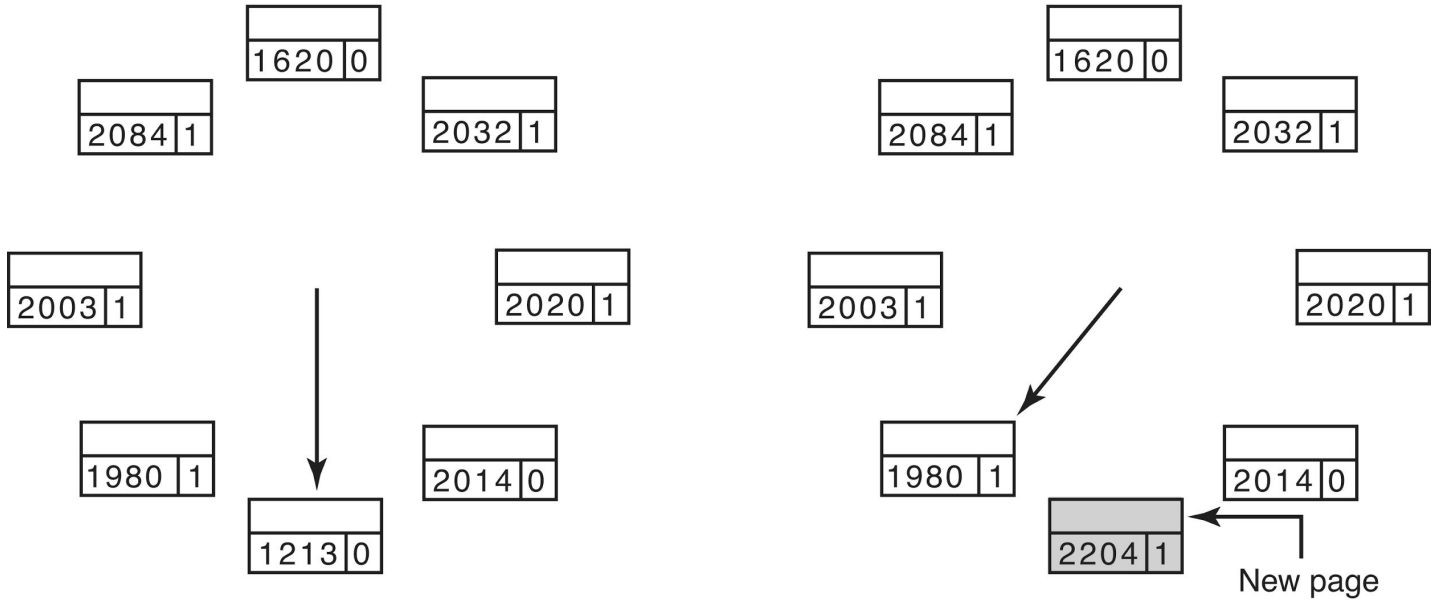

Wskazana strona jest czysta i stara → usuwamy! Jeśli była brudna planujemy zapis na dysk i lecimy dalej – czy ograniczyć liczbę współbieżnych zapisów? Jeśli zbiór roboczy zbyt mały → należy go powiększyć. Możemy regulować wartość τ!

Zarządzanie rozmiarem zbioru rezydentnego

Czy procesowi przydzielić **stałą** (ang. *fixed-allocation*) czy **zmienną liczbę ramek** (ang. *variable-allocation*)?

- Procesy mają różne potrzeby, które można badać mierząc **PFF**!
- A gdyby tak chcieć sprawiedliwie traktować grupy procesów?
- Czy błędy stron wątków zliczać osobno czy na koszt procesu?

zakres zastępowania stron (ang. *replacement scope*) → rozpatrywać wybór ofiar osobno w każdym procesie czy globalnie?

Zliczanie PFF trzeba zrobić mądrze… w trakcie życia procesu naturalnie istnieją pewne momenty, w który potrzebuje więcej stron.

Zarządzanie obciążeniem i wieloprogramowość

szamotanie (ang. thrashing) → zbiory rezydentne wszystkich procesów są zbyt małe i system nie ma wolnych ramek, zatem spędza dużo czasu na **wymianie stron** (ang. swapping).

Jak wybrnąć z szamotania?

- wyrzucić procesy o niskim priorytecie z RAM
- zamrozić proces z najszybciej rosnącym zbiorem rezydentnym
- wybrać proces ofiarę i ją zabić (Linux OOM killer)

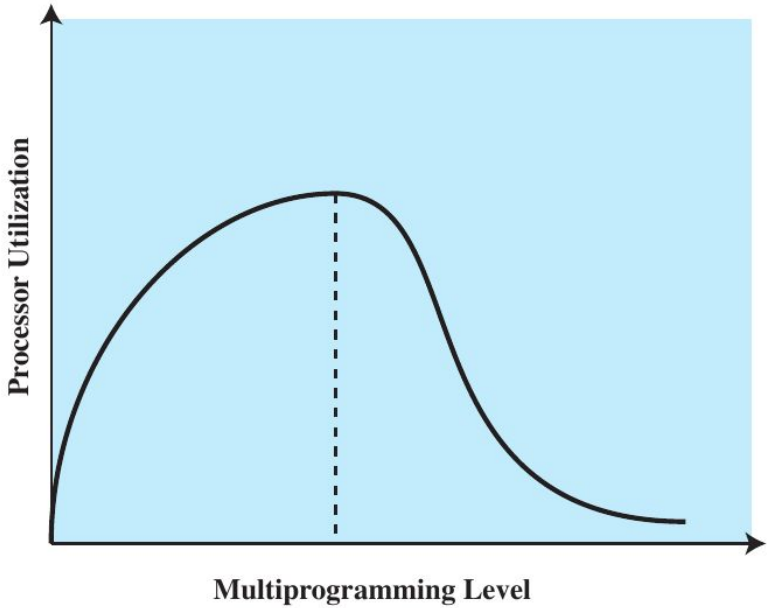

Przypinanie stron (*pinned / wired / locked pages*)

Po co zabraniać usuwania stron procesów z pamięci operacyjnej?

- chcemy zapewnić, że proces zawsze może się wykonywać
  (menadżer zadań do zabicia pamięciożernego procesu)
- proces musi szybko reagować na zdarzenia
  (system dostarcza pewnych gwarancji czasu rzeczywistego)

A co ze stronami jądra?

- nie możemy usunąć stron, na których leżą struktury danych
  (proces nie był używany od godziny → jego PCB musi być w RAM)
- transferujemy dane z użyciem DMA do dysku / karty sieciowej
  (urządzenia używają adresów fizycznych! nie możemy ani usunąć tych stron z RAM ani wykonywać ich relokacji → *locked pages*)

Pamięć drugorzędna

Strony zapisujemy w **obszarze wymiany** (ang. *swap area*).

Ciągły plik lub dowolne **urządzenie blokowe** → partycja dyskowa, dysk USB, pamięć karty graficznej, zRAM!

Służy do zachowania stanu systemu i procesów przy **hibernacji** na dysk!

Q: Co jeśli w pamięci były dane wrażliwe → hasła, klucze prywatne?
A: Obszar wymiany trzeba szyfrować!

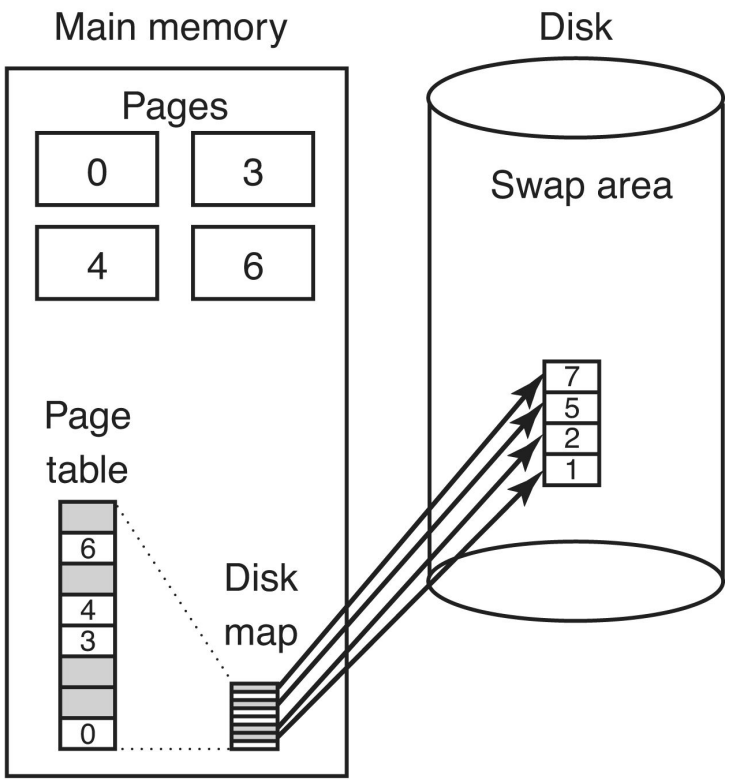

Pytania?